

El día que DeepSeek, Moonshot y MiniMax usaron a Claude como tutor particular

André Arturo González Zamora — Abril 2026

En febrero de 2026, Anthropic publicó algo que en el ecosistema de IA se sabía que era cuestión de tiempo pero que nadie había documentado tan abiertamente: tres laboratorios chinos —DeepSeek, Moonshot AI y MiniMax— habían utilizado técnicas fraudulentas para extraer capacidades de Claude y emplearlas en el entrenamiento de sus propios sistemas (El Independiente, 2026). El total: más de 16 millones de conversaciones a través de aproximadamente 24,000 cuentas falsas (El Boletín, 2026). A eso se le llama, técnicamente, un ataque de destilación. Y es exactamente tan audaz como suena.

Para entender qué pasó hay que tener claro qué es la destilación. Consiste en formular miles o millones de preguntas a un sistema avanzado, recopilar sus respuestas, y usarlas como base de entrenamiento de otro modelo (El Boletín, 2026). Es básicamente hacerle un examen oral a un modelo frontier, grabarlo todo, y enseñarle esas respuestas a tu propio modelo para que aprenda a comportarse igual. Los propios labs hacen esto internamente todo el tiempo —es cómo crean versiones más ligeras de sus modelos. El problema es cuando lo haces con el modelo de la competencia, a escala industrial, con cuentas falsas diseñadas para evitar los sistemas de detección.

Lo que diferencia esto de simplemente usar Claude para trabajar —como hacemos nosotros— es el volumen y la intención. Según el comunicado de Anthropic, el volumen, la estructura y el enfoque de los prompts eran distintos de los patrones de uso normales, reflejando una extracción deliberada de capacidades en lugar de un uso legítimo (El Independiente, 2026). No era gente preguntándole a Claude cómo optimizar una query. Era infraestructura coordinada, redes de cuentas que se rotaban cuando una era bloqueada —lo que Anthropic describe como un "hydra cluster"— de modo que cuando una cuenta era bloqueada, otra ocupaba su lugar (Xataka, 2026a).

Cada laboratorio tenía un objetivo distinto. DeepSeek buscaba que Claude detallara el proceso lógico detrás de respuestas complejas para generar insumos de entrenamiento que luego aplicaba en el desarrollo de sus propios modelos (IProup, 2026). Básicamente, le pedían a Claude que pensara en voz alta, paso a paso, para poder copiar no solo las respuestas sino el razonamiento detrás de ellas. Moonshot se orientó hacia el desarrollo de agentes capaces de usar herramientas y manipular entornos informáticos (GPTZone, 2026). Y el más agresivo fue MiniMax: casi la mitad de su tráfico fue redirigido para extraer capacidades del Claude más reciente en un plazo de 24 horas tras su lanzamiento (GPTZone, 2026) —una estrategia de "captúralo antes de que cambien las defensas."

Esto es lo que resulta genuinamente interesante del caso, más allá del drama geopolítico: revela cuánto del valor de un modelo frontier está en sus datos de entrenamiento y en cómo razona, no solo en la arquitectura. Si puedes inducir al modelo a que te explique su cadena de pensamiento a escala masiva, básicamente le estás haciendo un jailbreak epistemológico. No le robas los pesos —le robas la lógica.

Anthropic respondió reforzando sistemas de detección, endureciendo la verificación de cuentas y compartiendo indicadores técnicos con otros laboratorios. También aprovechó para hacer un argumento político: los ataques de destilación socavan los controles de exportación al permitir que laboratorios extranjeros cierren la brecha competitiva mediante la extracción de capacidades ya desarrolladas, sin recorrer el mismo proceso de investigación y entrenamiento (La Nación, 2026). En otras palabras: de nada sirve restringir chips si puedes simplemente preguntarle al modelo que ya existe.

Lo irónico es que esto confirma algo que ya sabíamos: la carrera de la IA no es solo de quién entrena el modelo más grande. Es de quién tiene acceso a los mejores datos de entrenamiento. Y si el modelo más capaz del mundo está disponible via API, siempre va a existir el incentivo de convertirlo en tu profesor particular. Anthropic puede parchear sus sistemas de detección todo lo que quiera —la dinámica de fondo no desaparece.

Referencias

- El Boletín. (2026, 26 de febrero). *Escalada en la guerra de la IA: Anthropic denuncia el uso masivo de Claude para entrenar modelos chinos*. <https://www.elboletin.com/escalada-en-la-guerra-de-la-ia-anthropic-denuncia-el-uso-masivo-de-claude-para-entrenar-modelos-chinos/>
- El Independiente. (2026, 24 de febrero). *Anthropic acusa a DeepSeek y otros laboratorios chinos de usar Claude de manera ilícita para entrenar sus IA*. <https://www.elindependiente.com/futuro/2026/02/24/anthropic-acusa-a-deepseek-y-otros-laboratorios-chinos-de-usar-claude-de-manera-ilicita-para-entrenar-sus-ia/>
- GPTZone. (2026, 24 de febrero). *Anthropic acusa a laboratorios chinos de entrenar a 3 modelos de IA con datos de Claude*. <https://gptzone.net/noticias/anthropic-3-modelos-ia-entrenan-con-claude>
- IProup. (2026, 24 de febrero). *Anthropic denunció una campaña china para replicar su modelo Claude*. <https://www.iproup.com/innovacion/65183-anthropic-denuncio-una-campana-china-para-replicar-su-modelo-claude>
- La Nación. (2026, 24 de febrero). *Anthropic acusa a tres empresas chinas de realizar ataques de destilación contra Claude para mejorar sus modelos*. <https://www.lanacion.com.ar/tecnologia/anthropic-acusa-a-tres-empresas-chinas-de-realizar-ataques-de-destilacion-contra-claude-para-mejorar-nid24022026/>
- Xataka. (2026a, 24 de febrero). *La IA ya es un campo de batalla: Anthropic acaba de acusar a DeepSeek y a otras empresas chinas de "destilar" Claude*. <https://www.xataka.com/robotica-e-ia/ia-campo-batalla-anthropic-accaba-acusar-a-deepseek-a-otras-empresas-chinas-destilar-claude>

Nota: La noticia refiere a destilación de Claude vía API en general, no específicamente a Claude Code. Si la leíste asociada a Claude Code, probablemente hubo cruce de contextos —el tema de fondo es el mismo y igual de relevante.